

# Systemidentifikation und Regelung in der Medizin

## 9. Vorlesung

### Modellbasierte prädiktive Regelung

Sommersemester 2020

26. Juni 2020

Thomas Schauer

Technische Universität Berlin  
Fachgebiet Regelungssysteme

---

## 9. Modellbasierte prädiktive Regelung

### 9.1 Allgemeine Grundlagen

#### 9.1.1 Bestandteile einer prädiktiven Regelung

1. Modell des zu regelnden Systems → **Nutzung zur Vorhersage des Systemverhaltens** in Abhängigkeit von der Stellgröße und beobachteten oder bekannten Störungen
2. **Referenztrajektorie** für den Systemausgang
3. **Gütefunktional**, das **minimiert** wird, um die optimale Stellgrößensequenz zu finden
4. Methode zur **Minimierung des Gütefunktional**s

#### 9.1.2 Idee

**Berechnung der zukünftigen Stellgrößentrajektorie** so, dass der Systemausgang nahe an dem gewünschten Referenzverlauf ist unter Berücksichtigung des Stellaufwands und Beschränkungen z.B. bei der Stellgröße.

---

## Receding Horizon Principle:

- Nur das erste Element  $u(k)$  der zukünftigen Stellgrößentrajektorie wird im Zeitschritt  $k$  auf die Strecke angewandt.
- Die komplette Optimierung wird dann für den Zeitschritt  $k + 1$  wiederholt.

### 9.1.3 Modell

- Beschreibung von deterministischen Verhalten (Beziehung von Stellgröße und Ausgang) als auch Störverhalten (deterministisch und/oder stochastisch)
- Möglicher Modellansatz: BJ-Modell - stochastische Modellierungsansatz für alle Störungen
- Beobachtung und Schätzung von Störungen über den Prädiktor (ständiger Vergleich vom gemessenen Ausgang und der Prädiktion)

### 9.1.4 Gütefunktional

$$J(k) = \underbrace{\sum_{i=H_s}^{H_p} (\hat{y}(k+i) - w(k+i))^2}_{\text{Tracking}} + \rho \underbrace{\sum_{i=0}^{H_p-d} \left( \underbrace{\frac{Q_n(q^{-1})}{Q_d(q^{-1})} u(k+i)}_{u^*(k+i)} \right)^2}_{\text{Stellaufwand}} \quad (1)$$

Zum Zeitpunkt  $k$  ergeben sich:

- $H_s$ : minimaler Gütefunktionalshorizont,  $H_s \geq d$  ( $d$  - Totzeit)
- $H_p$ : Prädiktionshorizont (Die Wahl von  $H_p$  ist nach oben begrenzt durch die Modellqualität.  $H_p$  sollte aber mindestens so groß gewählt werden, dass die Anstiegszeit erfasst wird.)
- $H_c$ : Stellhorizont (Dimension des Optimierungsproblems),  $H_c \leq H_p - d$   
Man beachte:  $u(k + H_p - d)$  ist die letzte Stellgröße, welche noch einen Einfluss auf  $\hat{y}(k + H_p)$  hat.
- $w(k)$  : Referenz

- $y(k)$  : gemessener Systemausgang
- $y(t)$  : wahrer kontinuierlicher Systemausgang
- $\hat{y}(k + i|k)$ : zum Zeitpunkt  $k$  prädiktierter Systemausgang  $i$  Schritte im Voraus
- $u(k - j)$ : bereits angewandte Stellgrößen  $j \geq 1$
- $\hat{u}(k + j)$ : zukünftige Stellgröße,  $j \geq 0$

**Bestrafung** von zu großen Sprüngen in der Stellgröße:

$$Q_d(q^{-1}) = 1, \quad Q_n(q^{-1}) = 1 - q^{-1} = \Delta, \quad \rho > 0 \quad (2)$$

### **Nebenbedingungen:**

Optimiert werden die  $H_c$  zukünftigen Stellgrößen  $\hat{u}(k)$  bis  $\hat{u}(k + H_c - 1)$ . Für die restlichen Stellgrößen  $\hat{u}(k + H_c)$  bis  $\hat{u}(k + H_p - d)$  nimmt man an

$$\hat{u}(k + i) = \hat{u}(k + H_c - 1), \quad H_c \leq i \leq H_p - d \quad (3)$$

oder

$$\hat{u}(k + i) = 0, \quad H_c \leq i \leq H_p - d. \quad (4)$$

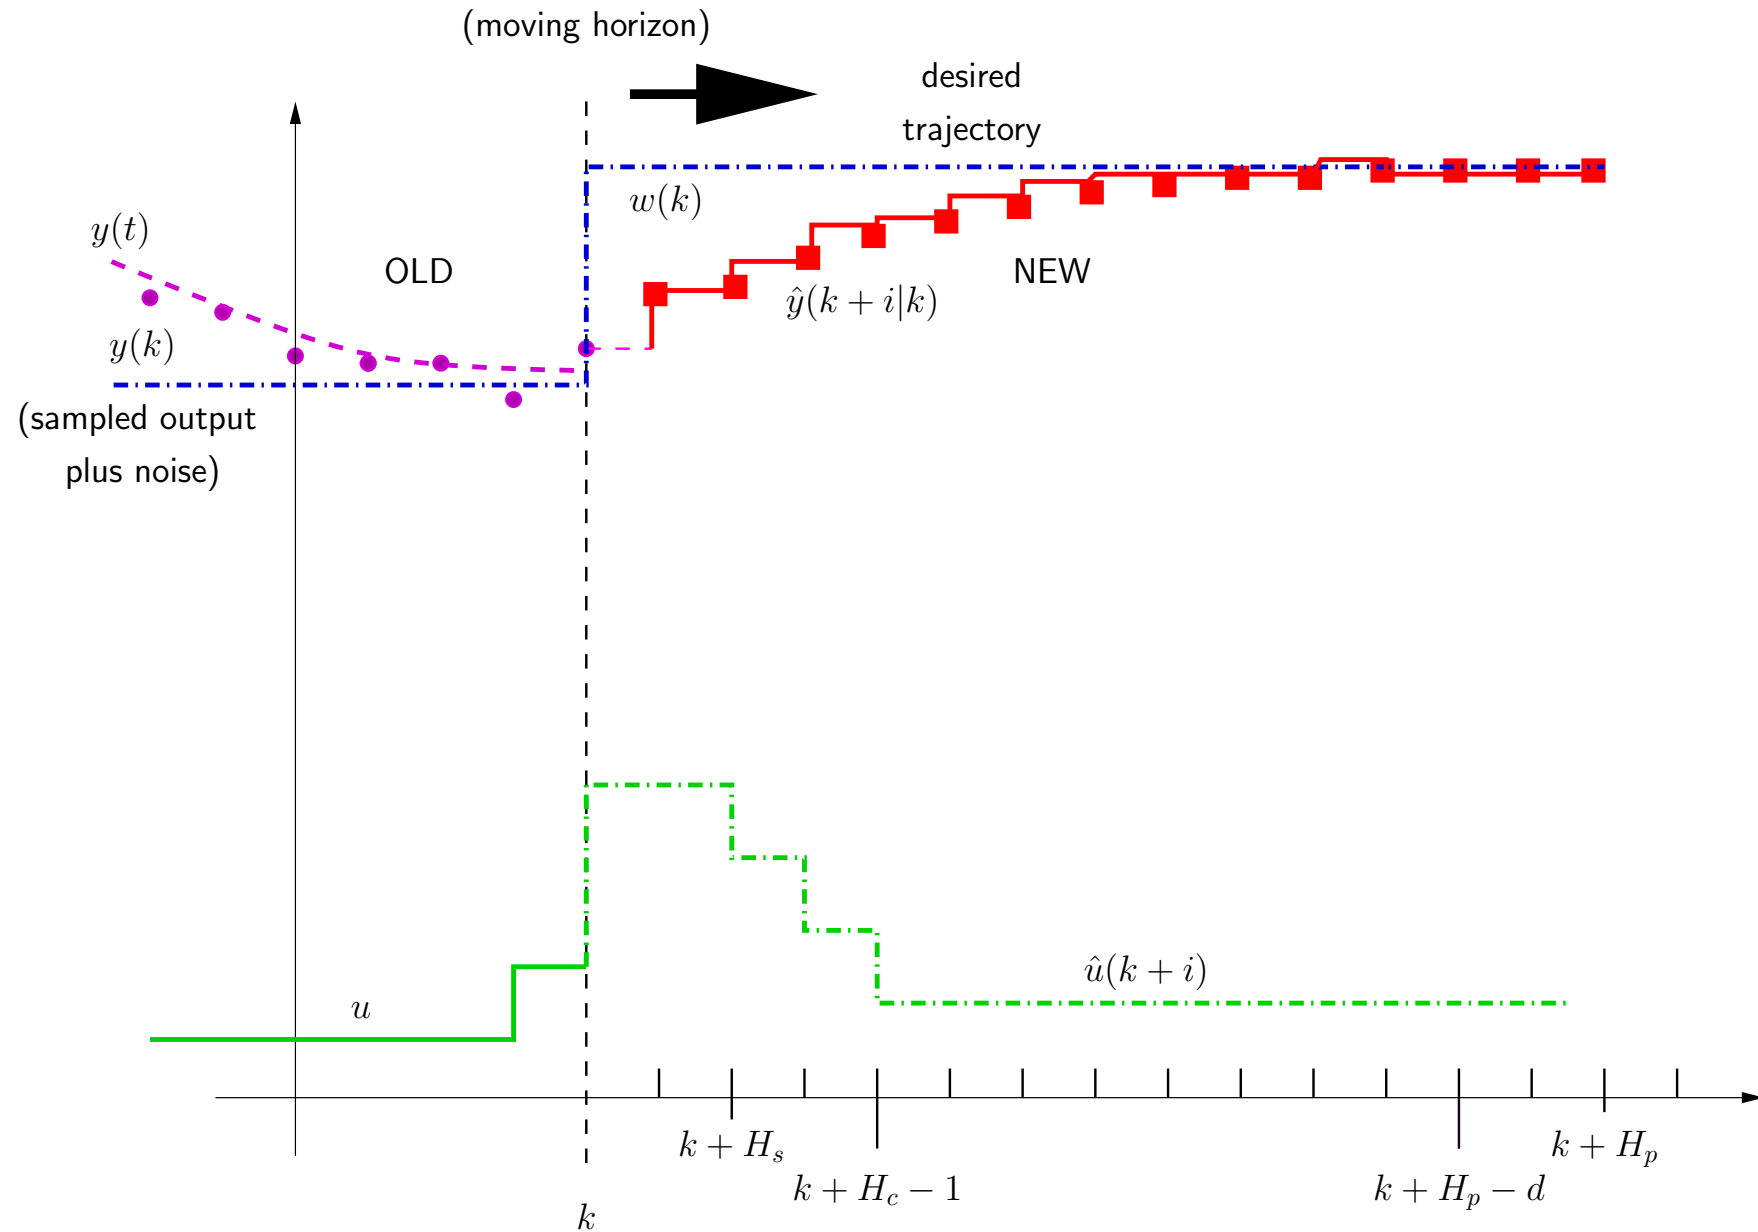


Abbildung: Prinzip der prädiktiven Regelung

### 9.1.5 Optimierung

Umschreibung des Gütefunktional in Vektorschreibweise:

$$J = (\hat{\mathbf{y}} - \mathbf{w})^T (\hat{\mathbf{y}} - \mathbf{w}) + \rho \mathbf{u}^{*T} \mathbf{u}^* \quad (5)$$

mit

$$\hat{\mathbf{y}} = \begin{bmatrix} \hat{y}(k + H_s) & \cdots & \hat{y}(k + H_p) \end{bmatrix}^T \quad \text{w : Referenz} \quad (6)$$

$$\mathbf{w} = \begin{bmatrix} w(k + H_s) & \cdots & w(k + H_p) \end{bmatrix}^T \quad (7)$$

$$\mathbf{u}^* = \begin{bmatrix} u^*(k) & \cdots & u^*(k + H_p - d) \end{bmatrix}^T \quad (8)$$

$$\hat{\mathbf{u}} = \begin{bmatrix} \hat{u}(k) & \cdots & \hat{u}(k + H_p - d) \end{bmatrix}^T \quad (9)$$

Minimierung des Gütefunktional bezüglich des kompletten Vektors zukünftiger Stellgrößen unter Berücksichtigung der oben genannten Nebenbedingungen (3)-(4) und Stellgrößenbeschränkungen.

Stellgrößenbeschränkungen:

$$\mathbf{u}_{lb} \leq \hat{\mathbf{u}} \leq \mathbf{u}_{ub}. \quad (10)$$

Umformulierung der Nebenbedingungen (3) in Matrixschreibweise:

$$\underbrace{\begin{bmatrix} 0 & \dots & 0 & \mathbf{1} & -1 & 0 & 0 & \dots & 0 & 0 \\ 0 & \dots & 0 & 1 & 0 & -1 & 0 & \dots & 0 & 0 \\ & & \vdots & & & & & \vdots & & \\ 0 & \dots & 0 & 1 & 0 & 0 & 0 & \dots & 0 & -1 \end{bmatrix}}_{\mathbf{S}} \underbrace{\begin{bmatrix} \hat{u}(k) \\ \vdots \\ \hat{u}(k + H_c - 2) \\ \mathbf{\hat{u}(k + H_c - 1)} \\ \hat{u}(k + H_c) \\ \hat{u}(k + H_c + 1) \\ \hat{u}(k + H_c + 2) \\ \vdots \\ \hat{u}(k + H_p - d - 1) \\ \hat{u}(k + H_p - d) \end{bmatrix}}_{\hat{\mathbf{u}}} = \underbrace{\begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}}_{\mathbf{t}} \quad (11)$$

$$\mathbf{S}\hat{\mathbf{u}} = \mathbf{t} \quad (12)$$



$$\begin{aligned}
\hat{u}(k + H_c) &= \hat{u}(k + H_c - 1) && \text{Genau wie Nebenbedingung (3)} \\
\hat{u}(k + H_c + 1) &= \hat{u}(k + H_c - 1) \\
&\vdots
\end{aligned}$$

Drückt man  $\hat{\mathbf{y}}$  als lineare Vektorfunktion von  $\hat{\mathbf{u}}$  aus (für lineare Modelle immer möglich) und schreibt auch  $\mathbf{u}^*$  als lineare Vektorfunktion von  $\hat{\mathbf{u}}$ , so lässt sich nach Umformungen das Gütefunktional schreiben als:

$$J = \frac{1}{2} \hat{\mathbf{u}}^T \mathbf{Q} \hat{\mathbf{u}} + \mathbf{c}^T \hat{\mathbf{u}} + \tilde{d} \quad (13)$$

Es ergibt sich dann folgendes Optimierungsproblem (Quadratic Programming):

$$\hat{\mathbf{u}}_{opt} = \arg \min_{\hat{\mathbf{u}}} J \quad (14)$$

$$\mathbf{u}_{lb} \leq \hat{\mathbf{u}} \leq \mathbf{u}_{ub} \quad (15)$$

$$\mathbf{S} \hat{\mathbf{u}} = \mathbf{t} \quad (16)$$

In MATLAB existiert bereits eine Funktion zur Lösung dieses Problems (siehe nachfolgende Erläuterungen).


---

**MATLAB-Implementierung für *Quadratic Programming***

---

```
%quadprog: Quadratic programming
%Minimize  $J = 1/2 * u\_hat' * Q * u\_hat + c' * u\_hat + d\_tilde$ 
%subject to:  $U * u\_hat \leq v$  (here  $U=[], v=[];$ )
%
%  $S * u\_hat = t$ 
%
%  $u\_lb \leq u\_hat \leq u\_ub$ 
[u_hat_opt, J_opt] = quadprog(Q, c, U, v, S, t, u_lb, u_ub, u_hat_0);
```

Gütefunktional bei Beschränkung der Stellgröße ( $H_c = 2$ )



## 9.2 Prädiktive Regelung bei einem BJ-Modellansatz

Formulierung der Stellgrößenbestrafung (2) in Vektor/Matrix-Darstellung:

$$u^*(k) = \hat{u}(k) - u(k-1) \quad ???$$

$$\underbrace{\begin{bmatrix} u^*(k) \\ u^*(k+1) \\ u^*(k+2) \\ \vdots \\ u^*(k+H_p-d) \end{bmatrix}}_{\mathbf{u}^*} = \underbrace{\begin{bmatrix} 1 & 0 & 0 & \cdots & 0 & 0 \\ -1 & 1 & 0 & \cdots & 0 & 0 \\ 0 & -1 & 1 & \cdots & 0 & 0 \\ \vdots & & \ddots & \ddots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & -1 & 1 \end{bmatrix}}_{\mathbf{\Phi}} \underbrace{\begin{bmatrix} \hat{u}(k) \\ \hat{u}(k+1) \\ \hat{u}(k+2) \\ \vdots \\ \hat{u}(k+H_p-d) \end{bmatrix}}_{\hat{\mathbf{u}}} + \underbrace{\begin{bmatrix} -1 \\ 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}}_{\mathbf{\Omega}} u(k-1)$$

$$\mathbf{u}^* = \mathbf{\Phi} \hat{\mathbf{u}} + \mathbf{\Omega} u(k-1)$$

Bei komplexerem Filter  $\frac{Q_n(q^{-1})}{Q_d(q^{-1})}$  muss man **Diophantische Gleichungen lösen**, um die Matrizen  $\mathbf{\Phi}$  und  $\mathbf{\Omega}$  zu bestimmen (siehe nächste Folien).

### *i*-Schritt-Vorausprädiktion (i-step-ahead-prediction)

Gegeben sei die Box-Jenkins-Struktur:

$$y(k) = \frac{B(q^{-1})}{A(q^{-1})}u(k-d) + \frac{C(q^{-1})}{D(q^{-1})}e(k) \quad (17)$$

Ziel: Herleitung eines Algorithmus zur **Ermittlung der optimalen** *i*-Schritt-Vorausprädiktion  $\hat{y}(k+i|k)$  des Systemausganges  $y(k+i)$  unter Annahme folgender Informationen zum Zeitpunkt  $k$ : Ausgangsmessungen bis zum Zeitpunkt  $k$  sowie **Stellgrößen bis zum Zeitpunkt  $k+i-d$** . Man beachte, dass die Stellgrößen bis zum Zeitpunkt  $k-1$  alt sind und bereits auf die Strecke angewandt wurden. **Ab den Zeitpunkt  $k$  spricht man von zukünftigen Stellgrößen** (Schätzungen).

## Diophantische Gleichung

Gegeben sei eine Transferfunktion  $X(q^{-1})/Y(q^{-1})$  und ein Signal  $s(k+i)$  ( $i$  Schritte voraus). Gesucht werden nun folgende durch Filterung des Signals  $s(k+i)$  mit  $X(q^{-1})/Y(q^{-1})$  entstehende Anteile:

- Anteil, der nur alte (bekannte) Werte von  $s(l)$ ,  $l = \dots, k-1, k$  enthält.
- Anteil, der nur zukünftige Werte von  $s(l)$ ,  $l = k+1, \dots, k+i$  enthält.

Ermittlung durch Lösen einer Diophantischen Gleichung:

$$\frac{X(q^{-1})}{Y(q^{-1})} = E_i(q^{-1}) + q^{-i} \frac{F_i(q^{-1})}{Y(q^{-1})} \quad (18)$$

- $E_i(q^{-1})$  - bezogen auf zukünftige Werte
- $q^{-i} \frac{F_i(q^{-1})}{Y(q^{-1})}$  - bezogen auf bekannte (alte) Werte

Lösungsansätze:

- Rekursive Formel:  $E_i, F_i \Rightarrow F_{i+1}, E_{i+1}$
- Polynomdivision (long division)

Voraussetzungen:

- $Y$  ist **monisch**.
- $Y$  und  $X$  sind **teilerfremd**. = **mutually prime**

Polynome:

$$Y(q^{-1}) = 1 + y_1 q^{-1} + \cdots + y_{n_Y} q^{-n_Y}$$

$$X(q^{-1}) = x_0 + x_1 q^{-1} + \cdots + x_{n_X} q^{-n_X}$$

$$E_i(q^{-1}) = e_{i,0} + e_{i,1} q^{-1} + \cdots + e_{i,n_{E_i}} q^{-n_{E_i}}$$

$$F_i(q^{-1}) = f_{i,0} + f_{i,1} q^{-1} + \cdots + f_{i,n_{F_i}} q^{-n_{F_i}}$$

Gradabschätzungen:

- $\deg E_i =$ 

$$\begin{cases} i - 1 & \text{für } \deg Y > 0 & \text{(absorbiert } i \text{ zukünftige Werte: } s(k+i)q^{-(i-1)} = s(k+1) \text{ bis } s(k+i)) \\ \min(i-1, n_X) & \text{für } \deg Y = 0 & \text{(siehe nächste Folie)} \end{cases}$$
- $\deg F_i = \deg(q^i X - q^i Y E_i) = \max(-i + n_X, -i + n_Y + i - 1) = \max(-i + n_X, n_Y - 1)$

**Beispiele:** Annahme eines Signals  $s(k)$  (ab  $k + 1$  ist zukünftig).

- $\deg X = 3, \deg Y = 0, i = 5$

$$\begin{aligned} \deg F &= \max(-5+3, 0-1) = -1 \\ \deg E &= \min(5-1, 3) = 3 \end{aligned}$$

$$X(q^{-1})s(k+5) = \underbrace{(x_0 + x_1q^{-1} + x_2q^{-2} + x_3q^{-3})}_{E_5} s(k+5)$$

- $\deg X = 3, \deg Y = 0, i = 2$

$$\begin{aligned} X(q^{-1})s(k+2) &= \underbrace{(x_0 + x_1q^{-1})}_{E_2} s(k+2) + \underbrace{(x_2q^{-2} + x_3q^{-3})}_{q^{-2}F_2(q^{-1})} s(k+2) \\ &= \underbrace{(x_0 + x_1q^{-1})}_{E_2} s(k+2) + \underbrace{(x_2 + x_3q^{-1})}_{F_2(q^{-1})} s(k) \end{aligned}$$

$$\begin{aligned} \deg F &= \max(-2+3, 0-1) = 1 \\ \deg E &= \min(2-1, 3) = 1 \end{aligned}$$



## Lösung mittels Polynomdivision (long devision):

Beispiel:  $X(q^{-1}) = 1$ ,  $Y(q^{-1}) = (1 - q^{-1})^2 = 1 - 2q^{-1} + q^{-2}$

$$\text{Gesucht: } \frac{X(q^{-1})}{Y(q^{-1})} = E_i(q^{-1}) + q^{-i} \frac{F_i(q^{-1})}{Y(q^{-1})}, \quad i = 1, 2$$

Für 1-Schritt-Prädiktion:

$$\frac{1}{1 - 2q^{-1} + q^{-2}} = \frac{q^2}{q^2 - 2q + 1}$$

$$q^2 : (q^2 - 2q + 1) = 1 + \frac{2q - 1}{q^2 - 2q + 1}$$

$$\frac{-(q^2 - 2q + 1)}{2q - 1} \quad \text{simply divide here}$$

$$1 + \frac{2q - 1}{q^2 - 2q + 1} = 1 + \frac{2q^{-1} - q^{-2}}{1 - 2q^{-1} + q^{-2}} = \underbrace{1}_{E_1(q^{-1})} + q^{-1} \frac{\underbrace{2 - q^{-1}}_{F_1(q^{-1})}}{1 - 2q^{-1} + q^{-2}}$$

make is so that we have  
q-1 on the front!

1-Schritt

Für 2-Schritt-Prädiktion:

$$\begin{array}{r}
 q^2 \\
 -(q^2 - 2q + 1) \\
 \hline
 2q - 1 \\
 -(2q - 4 + 2q^{-1}) \\
 \hline
 3 - 2q^{-1}
 \end{array}$$

where does this come from?

$$: ((q^2 - 2q + 1) = 1 + 2q^{-1} + \frac{3 - 2q^{-1}}{q^2 - 2q + 1}$$

divide twice?

$$1 + 2q^{-1} + \frac{3 - 2q^{-1}}{q^2 - 2q + 1} = 1 + 2q^{-1} + \frac{3q^{-2} - 2q^{-3}}{1 - 2q^{-1} + q^{-2}} = \underbrace{1 - 2q^{-1}}_{E_2(q^{-1})} + q^{-2} \frac{\underbrace{3 - 2q^{-1}}_{F_1(q^{-1})}}{1 - 2q^{-1} + q^{-2}}$$

2-Schritt

## Rekursiver Algorithmus zur Lösung der Diophantischen Gleichung:

$$X(q^{-1}) = Y(q^{-1})E_{j+1}(q^{-1}) + q^{-(j+1)}F_{j+1}(q^{-1}) \quad (19)$$

Diophantische Gleichung für  $j$ :

$$X(q^{-1}) = Y(q^{-1})E_j(q^{-1}) + q^{-j}F_j(q^{-1}) \quad (20)$$

Die Subtraktion (19)-(20) ergibt

$$0 = Y(E_{j+1} - E_j) + q^{-j} (q^{-1}F_{j+1} - F_j), \quad (21)$$

Mit  $\deg E_{j+1} = \deg E_j + 1$  erhält man

$$E_{j+1} - E_j = \tilde{E} + e_{j+1,j}q^{-j} \quad (22)$$

und damit

$$0 = Y(\tilde{E} + e_{j+1,j}q^{-j}) + q^{-j} (q^{-1}F_{j+1} - F_j) \quad (23)$$

$$0 = Y\tilde{E} + q^{-j} (q^{-1}F_{j+1} - F_j + e_{j+1,j}Y). \quad (24)$$

Damit die Gleichung zu Null wird, muss gelten  $\tilde{E} \equiv 0$  ( $Y$  ist ungleich Null).  
wieso???

Daraus folgt

$$q^{-1} \mathbf{F}_{j+1} - \mathbf{F}_j + \mathbf{Y} e_{j+1,j} = 0 \quad (25)$$

*Rekursive Lösung* der Diophantischen Gleichung:

Aus  $\tilde{\mathbf{E}} = 0$  und der Definition von  $\tilde{\mathbf{E}}$  folgt:

$$\mathbf{E}_{j+1} = \mathbf{E}_j + e_{j+1,j} q^{-j} \quad (26)$$

Ausschreiben von Gl. (25) liefert:

$$\begin{aligned} q^{-1} (f_{j+1,0} + f_{j+1,1} q^{-1} + \cdots + f_{j+1,n_{F_{j+1}}} q^{-n_{F_{j+1}}}) \\ - (f_{j,0} + f_{j,1} q^{-1} + \cdots + f_{j,n_{F_j}} q^{-n_{F_j}}) \\ + (1 + y_1 q^{-1} + \cdots + y_{n_Y} q^{-n_Y}) e_{j+1,j} = 0 \end{aligned}$$

Koeffizientenvergleich:

$$\begin{aligned}
 -f_{j,0} + e_{j+1,j} &= 0 \rightarrow e_{j+1,j} = f_{j,0} \\
 f_{j+1,0} &= f_{j,1} - y_1 e_{j+1,j} \\
 f_{j+1,1} &= f_{j,2} - y_2 e_{j+1,j} \\
 &\vdots \\
 &\text{immer vom alten Wert abh ngig} \\
 f_{j+1,n_{F_{j+1}}} &= f_{j,n_{F_{j+1}}+1} - y_{n_{F_{j+1}}+1} e_{j+1,j}
 \end{aligned}$$

mit  $n_{F_{j+1}} = \max(n_X - (j+1), n_Y - 1)$ .

Anfangswerte f r  $E_1, F_1$

$$j = 1$$

$$X = YE_1 + q^{-1}F_1 \tag{27}$$

Da  $Y$  monisch ist und  $\deg E_1 = 0$  ergibt sich

$$E_1 = x_0 \text{ und } F_1 = q(X - x_0 Y).$$

Zusammenfassung des Algorithmus (gegeben:  $X(q^{-1}), Y(q^{-1})$  ( $\deg Y \geq 1$ ),  $i \geq 1$ ):

1. Startwerte berechnen:  $j = 1, E_1 = x_0$  und  $F_1 = q(X - x_0 Y)$ .

Falls  $i = 1 = j$ , hier beenden.

2.  $E_{j+1}$  berechnen:  $e_{j+1,j} = f_{j,0}$ ,  $E_{j+1} = E_j + e_{j+1,j}q^{-j}$

3.  $F_{j+1}$  berechnen:

$$f_{j+1,0} = f_{j,1} - y_1 e_{j+1,j}$$

$$f_{j+1,1} = f_{j,2} - y_2 e_{j+1,j}$$

$$\vdots$$

$$f_{j+1,n_{F_{j+1}}} = f_{j,n_{F_{j+1}}+1} - y_{n_{F_{j+1}}+1} e_{j+1,j}$$

mit  $n_{F_{j+1}} = \max(n_X - j - 1, n_Y - 1)$ .

4.  $j = j + 1$ , falls  $j = i$ , hier beenden, ansonsten zu Schritt 2.

Die Formeln im 3. Schritt lassen sich in Polynomform wie folgt schreiben:

$$F_{j+1} = (F_j - f_{j,0})q - (Y - 1)qe_{j+1,j} = q(F_j - Yf_{j,0})$$

... Herleitung der i-Schritt-voraus-Prädiktion für das Box-Jenkins-Modell

$$y(k+i) = \frac{B(q^{-1})}{A(q^{-1})}u(k-d+i) + \underbrace{\frac{C(q^{-1})}{D(q^{-1})}e(k+i)}_{\zeta(k+i)}, \quad i \geq d \quad (28)$$

(a) Separation der Störungen

$$\frac{C}{D} = E_i + q^{-i} \frac{F_i}{D} \quad (29)$$

- Bekannt:  $\dots, k-1, k$
- Zukünftig:  $k+1, \dots, k+i$

Nach Lösen der Dio.-Gleichung:

$$\zeta(k+i) = E_i e(k+i) + q^{-i} \frac{F_i}{D} e(k+i) = E_i e(k+i) + \frac{F_i}{D} e(k) \quad (30)$$

Schätzung von  $\frac{F_i}{D}e(k)$ :

$$y(k) = \left. \frac{B}{A}u(k-d) + \frac{C}{D}e(k) \right| \cdot \frac{F_i}{C} \quad (31)$$

$$\frac{F_i}{D}e(k) = \frac{F_i}{C} \left( y(k) - \frac{B}{A}u(k-d) \right) \quad (32)$$

Dies stellt eine Tiefpassfilterung der Prädiktionsfehler dar. Es folgt nun

$$y(k+i) = \frac{B(q^{-1})}{A(q^{-1})}u(k-d+i) + \frac{F_i}{C} \left( y(k) - \frac{B}{A}u(k-d) \right) + E_i e(k+i) \quad (33)$$

Da zukünftige Werte von  $e$  nicht bekannt sind und der Erwartungswert Null ist, folgt für den Prädiktor:

$$\hat{y}(k+i) = \frac{B(q^{-1})}{A(q^{-1})}u(k-d+i) + \frac{F_i}{C} \left( y(k) - \frac{B}{A}u(k-d) \right) \quad (34)$$



Separation von bekannten und zukünftigen Stellgrößen:

$$\frac{B}{A} = G_i + q^{-i+d-1} \frac{H_i}{A} \quad (35)$$

- Bekannt:  $\dots, k-2, k-1$
- Zukünftig:  $k, k+1, \dots, k+i-d, i \geq d$
- $\deg G_i = i-d, i \geq d$

Für den Prädiktor folgt dann:

$$\hat{y}(k+i) = G_i u(k-d+i) + \frac{H_i}{A} u(k-1) + \frac{F_i}{C} \left( y(k) - \frac{B}{A} u(k-d) \right) \quad (36)$$

Für den  $i$ -Schritt-voraus-Prädiktor muss man folglich zwei Diophantische Gleichungen lösen:

$$\frac{B(q^{-1})}{A(q^{-1})} = G_i(q^{-1}) + q^{-i+d-1} \frac{H_i(q^{-1})}{A(q^{-1})} \quad (37)$$

$$\frac{C(q^{-1})}{D(q^{-1})} = E_i(q^{-1}) + q^{-i} \frac{F_i(q^{-1})}{D(q^{-1})}. \quad (38)$$

Für die Lösung der Diophantischen Gleichungen anhand des rekursiven Algorithmus wird eine Matlab-Routine in der Übung erstellt. Die Polynome  $G_i$ ,  $H_i$ ,  $E_i$  und  $F_i$  werden für alle zukünftigen Schritte ( $i = H_s \dots H_p$ ) berechnet.

Gradabschätzungen für  $H_i$ ,  $F_i$  und  $G_i$ :

$$\begin{aligned} \deg G_i &= i - d, & i &= H_s \dots H_p, & H_s &\leq d \\ \deg H_i &= j, & j &= \max(\deg B - (i - d + 1), \deg A - 1) = \deg A - 1 \\ \deg F_i &= j, & j &= \max(\deg C - i, \deg D - 1) = \deg D - 1 \end{aligned}$$

Tabelle 1: Anwendung des rekursiven Algorithmus für dieses Problem ( $i \geq d$ ).

Algorithmus	C/D	B/A
X	C	B
Y	D	A
$E_i$	$E_i$	$G_i$
$F_i$	$F_i$	$H_i$
$i$	$i$	$i - d + 1$

## Filterung

$$\hat{y}(k+i|k) = \mathbf{G}_i(q^{-1})\hat{u}(k+i-d) + \frac{\mathbf{H}_i(q^{-1})}{\mathbf{A}(q^{-1})}u(k-1) + \frac{\mathbf{F}_i(q^{-1})}{\mathbf{C}(q^{-1})}(y(k) - \hat{y}(k)) \quad (39)$$

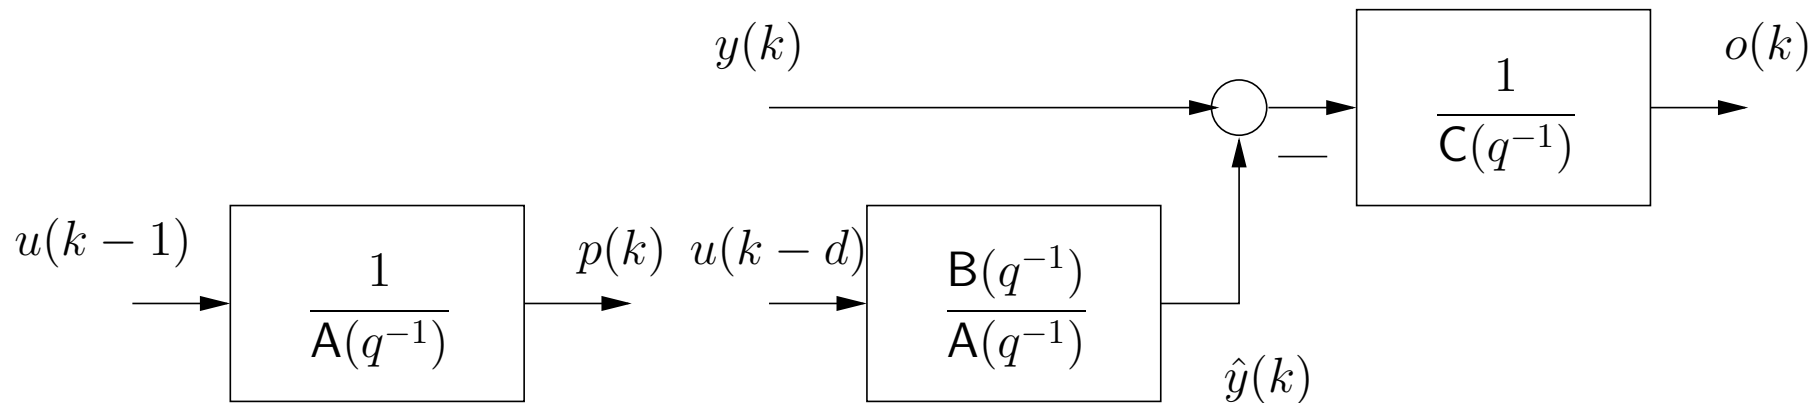


Abbildung: Filter

$$\hat{y}(k+i|k) = \mathbf{G}_i(q^{-1})\hat{u}(k+i-d) + \mathbf{H}_i(q^{-1})p(k) + \mathbf{F}_i(q^{-1})o(k) \quad (40)$$

## Vektor/Matrix Darstellung

$G_i, H_i$  und  $F_i$  werden in Matrizen gespeichert. Somit haben wir eine Dreiecksmatrix  $\mathbf{G}$  mit Dimension  $(H_p - H_s + 1) \times (H_p - d + 1)$ , eine Matrix  $\mathbf{H}$  mit Dimension  $(H_p - H_s + 1) \times (\deg(\mathbf{A}(q^{-1})))$  und  $\mathbf{F}$  mit Dimension  $(H_p - H_s + 1) \times (\deg(\mathbf{D}(q^{-1})))$ , die dann für die Prädiktion des Ausgangs des Systems in (41) eingesetzt werden.

Die Vektor/Matrix-Schreibweise für den Prädiktor lautet:

$$\hat{\mathbf{y}} = \mathbf{G}\hat{\mathbf{u}} + \mathbf{H}\hat{\mathbf{p}} + \mathbf{F}\hat{\mathbf{o}},$$

wobei die Vektoren  $\hat{\mathbf{p}}$  und  $\hat{\mathbf{o}}$  alte Werte der Ausgänge der beiden Filter in der Abbildung Filter beinhalten. Folglich hat man die folgende Darstellung für die Prädiktion von  $H_p - H_s$ -Schritten:

$$\underbrace{\begin{bmatrix} \hat{y}(k + H_s | k) \\ \hat{y}(k + H_s + 1 | k) \\ \vdots \\ \hat{y}(k + H_p - 1 | k) \\ \hat{y}(k + H_p | k) \end{bmatrix}}_{\hat{\mathbf{y}}} = \underbrace{\begin{bmatrix} g_{H_s,0} & 0 & \cdots & 0 & 0 \\ g_{H_s+1,1} & g_{H_s+1,0} & \cdots & 0 & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ g_{H_p-1,H_p-d-1} & g_{H_p-1,H_p-d-2} & \cdots & g_{H_p-1,0} & 0 \\ g_{H_p,H_p-d} & g_{H_p,H_p-d-1} & \cdots & g_{H_p,1} & g_{H_p,0} \end{bmatrix}}_{\mathbf{G}} \underbrace{\begin{bmatrix} \hat{u}(k) \\ \hat{u}(k+1) \\ \vdots \\ \hat{u}(k + H_p - d) \end{bmatrix}}_{\hat{\mathbf{u}}} \\
 + \underbrace{\begin{bmatrix} h_{H_s,0} & \cdots & h_{H_s,\deg(A)-1} \\ h_{H_s+1,0} & \cdots & h_{H_s+1,\deg(A)-1} \\ \vdots & \vdots & \vdots \\ h_{H_p-1,0} & \cdots & h_{H_p-1,\deg(A)-1} \\ h_{H_p,0} & \cdots & h_{H_p,\deg(A)-1} \end{bmatrix}}_{\mathbf{H}} \underbrace{\begin{bmatrix} p(k) \\ p(k-1) \\ \vdots \\ p(k - \deg(A) - 1) \end{bmatrix}}_{\hat{\mathbf{p}}} \\
 + \underbrace{\begin{bmatrix} f_{H_s,0} & \cdots & f_{H_s,\deg(D)-1} \\ f_{H_s+1,0} & \cdots & f_{H_s+1,\deg(D)-1} \\ \vdots & \vdots & \vdots \\ f_{H_p-1,0} & \cdots & f_{H_p-1,\deg(D)-1} \\ f_{H_p,0} & \cdots & f_{H_p,\deg(D)-1} \end{bmatrix}}_{\mathbf{F}} \underbrace{\begin{bmatrix} o(k) \\ o(k-1) \\ \vdots \\ o(k - \deg(D) - 1) \end{bmatrix}}_{\hat{\mathbf{o}}}$$

Einsetzen von (17) und (41) in das Gütefunktional (5):

$$J = (\mathbf{G}\hat{\mathbf{u}} + \mathbf{H}\hat{\mathbf{p}} + \mathbf{F}\hat{\mathbf{o}} - \mathbf{w})^T (\mathbf{G}\hat{\mathbf{u}} + \mathbf{H}\hat{\mathbf{p}} + \mathbf{F}\hat{\mathbf{o}} - \mathbf{w}) + \rho(\Phi\hat{\mathbf{u}} + \mathbf{\Omega}u(k-1))^T (\Phi\hat{\mathbf{u}} + \mathbf{\Omega}u(k-1)) \quad (41)$$

Ausgehend von der Gleichung (41) ergibt sich folgende Formel für das Gütefunktional:

$$\begin{aligned} J &= (\mathbf{G}\hat{\mathbf{u}} + \mathbf{H}\hat{\mathbf{p}} + \mathbf{F}\hat{\mathbf{o}} - \mathbf{w})^T (\mathbf{G}\hat{\mathbf{u}} + \mathbf{H}\hat{\mathbf{p}} + \mathbf{F}\hat{\mathbf{o}} - \mathbf{w}) + \\ &\quad + \rho(\Phi\hat{\mathbf{u}} + \mathbf{\Omega}u(k-1))^T (\Phi\hat{\mathbf{u}} + \mathbf{\Omega}u(k-1)) \\ &= (\hat{\mathbf{u}}^T \mathbf{G}^T + \hat{\mathbf{p}}^T \mathbf{H}^T + \hat{\mathbf{o}}^T \mathbf{F}^T - \mathbf{w}^T) (\mathbf{G}\hat{\mathbf{u}} + \mathbf{H}\hat{\mathbf{p}} + \mathbf{F}\hat{\mathbf{o}} - \mathbf{w}) + \\ &\quad + \rho(\hat{\mathbf{u}}^T \Phi^T + u(k-1)^T \mathbf{\Omega}^T) (\Phi\hat{\mathbf{u}} + \mathbf{\Omega}u(k-1)) \end{aligned}$$

mit  $u(k-1)^T = u(k-1)$ , da  $u(k-1)$  ein Skalar ist, ergibt sich dann:

$$\begin{aligned}
 J = & \hat{\mathbf{u}}^T (\mathbf{G}^T \mathbf{G} + \rho \Phi^T \Phi) \hat{\mathbf{u}} + \underbrace{(\hat{\mathbf{u}}^T \mathbf{G}^T)(\mathbf{H} \hat{\mathbf{p}} + \mathbf{F} \hat{\mathbf{o}} - \mathbf{w})}_{x} + (\hat{\mathbf{p}}^T \mathbf{H}^T + \hat{\mathbf{o}}^T \mathbf{F}^T - \mathbf{w}^T)(\mathbf{G} \hat{\mathbf{u}}) \\
 & + \underbrace{(\hat{\mathbf{p}}^T \mathbf{H}^T + \hat{\mathbf{o}}^T \mathbf{F}^T - \mathbf{w}^T)(\mathbf{H} \hat{\mathbf{p}} + \mathbf{F} \hat{\mathbf{o}} - \mathbf{w})}_{\text{const.}} + \underbrace{\rho \hat{\mathbf{u}}^T \Phi^T \Omega u(k-1)}_z + \rho u(k-1) \Omega^T \Phi \hat{\mathbf{u}} \\
 & + \underbrace{u(k-1) \Omega^T \Omega u(k-1)}_{\text{const.}}
 \end{aligned}$$

Da  $x = x^T = (\mathbf{H} \hat{\mathbf{p}} + \mathbf{F} \hat{\mathbf{o}} - \mathbf{w})^T \mathbf{G} \hat{\mathbf{u}}$  und  $z = z^T = \rho u(k-1) \Omega^T \Phi \hat{\mathbf{u}}$  gilt, folgt

$$\begin{aligned}
 J = & \hat{\mathbf{u}}^T (\mathbf{G}^T \mathbf{G} + \rho \Phi^T \Phi) \hat{\mathbf{u}} + 2(\mathbf{H} \hat{\mathbf{p}} + \mathbf{F} \hat{\mathbf{o}} - \mathbf{w})^T \mathbf{G} \hat{\mathbf{u}} + 2\rho u(k-1) \Omega^T \Phi \hat{\mathbf{u}} + \tilde{d} \\
 = & \hat{\mathbf{u}}^T \underbrace{(\mathbf{G}^T \mathbf{G} + \rho \Phi^T \Phi)}_{\frac{1}{2} \mathbf{Q}} \hat{\mathbf{u}} + 2 \underbrace{((\mathbf{H} \hat{\mathbf{p}} + \mathbf{F} \hat{\mathbf{o}} - \mathbf{w})^T \mathbf{G} + \rho u(k-1) \Omega^T \Phi)}_{\mathbf{c}^T} \hat{\mathbf{u}} + \underbrace{\tilde{d}}_{\text{const.}}
 \end{aligned}$$

Nun haben wir die erforderliche Form für das Gütefunktional entsprechend Gleichung (13), um das quadratische Problem in Matlab lösen zu können.



### 9.3 Einstellparameter der MPC

1. Gewicht  $\rho$  (Geschwindigkeit, Stellaufwand  $\Leftrightarrow$  Rauschempfindlichkeit)
2. Störgrößenmodell (C und D) (Schätzung von deterministischen Störungen  $\Leftrightarrow$  Rauschempfindlichkeit)
3. Horizonte  $H_p$  (Stabilität) und  $H_c$  (Rechenaufwand, Stabilität)